Activité — Partie I : RAG multimodal agentique

Cahier des charges pédagogique et schéma d'architecture

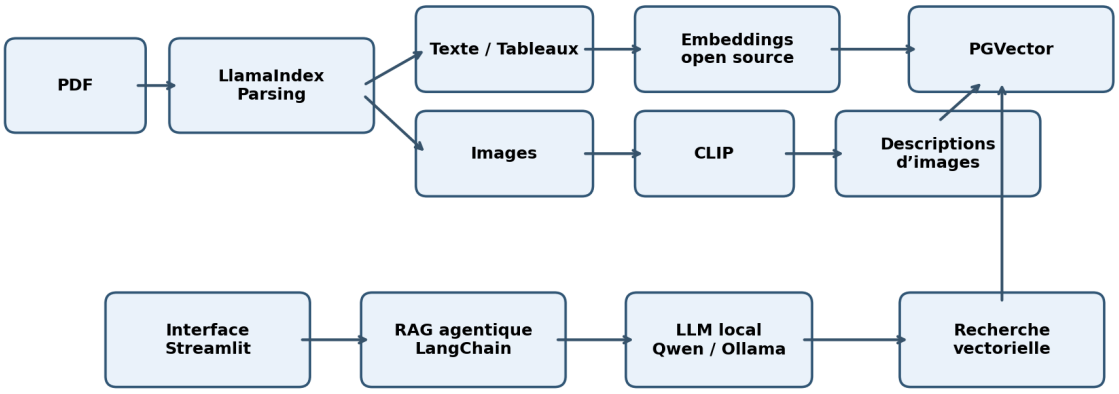
1. Objectif

Développer une application de question-réponse sur des documents PDF contenant du texte, des images et des tableaux. Le système devra indexer les contenus de manière multimodale et produire des réponses contextualisées à l'aide d'un LLM open source et d'un orchestrateur agentique.

2. Travail demandé

1. **Sélection du document —** Choisir un fichier PDF quelconque contenant du texte, des images et des tableaux.
2. **Extraction et indexation —** Utiliser LlamaIndex pour analyser le PDF et extraire le texte, les images et les tableaux. Produire des embeddings avec un modèle open source, puis stocker les vecteurs et métadonnées dans PGVector (PostgreSQL).
3. **Traitement des images —** Utiliser CLIP pour représenter les images et/ou faciliter leur recherche. Générer des descriptions textuelles des images et les indexer afin de les rendre interrogeables.
4. **Question-réponse et génération —** Construire un pipeline RAG avec un LLM open source, par exemple Qwen exécuté via Ollama. Récupérer les passages pertinents et produire une réponse fondée sur le contexte retrouvé.
5. **Interface utilisateur —** Créer une interface Streamlit permettant le chargement du PDF, la saisie des questions et l'affichage des réponses.
6. **Orchestration agentique —** Rendre le RAG agentique avec LangChain : sélection d'outils de recherche, interrogation de l'index, gestion du contexte et génération de la réponse.

3. Schéma d’architecture fonctionnelle



Indexation multimodale (haut) • Question-réponse agentique (bas)

Le flux d’indexation part du PDF vers LlamaIndex, puis vers les embeddings et PGVector. Le flux de requête part de Streamlit, passe par l’agent LangChain, le LLM et la recherche vectorielle, avant de retourner une réponse à l’utilisateur.

4. Livrables attendus

- Code source documenté (indexation, recherche, génération et orchestration).
- Base PGVector alimentée avec les contenus du PDF et leurs métadonnées.
- Interface Streamlit fonctionnelle avec démonstration sur un PDF multimodal.
- Note technique décrivant les modèles choisis, les outils, les limites et des exemples de questions/réponses.

5. Schéma original du tableau

